MongoDB

A DOCUMENT-ORIENTED DATABASE

Framework di aggregazione

AGGREGATE

Framework di aggregazione

Il framework di aggregazione permette di applicare **trasformazioni e aggregazioni** sui documenti di una collezione

E' costituito da una serie di **operatori di pipeline**, *mattoni* che possono essere liberamente combinati tra loro (anche più volte ed in qualunque ordine) per dar vita ad interrogazioni più o meno complesse

- Match, Project, Group, Unwind, Sort, Limit, Skip

Non solo aggregazioni: l'elevata espressività del framework consente di formulare **interrogazioni che non si potevano fare col Find**

- Applicare trasformazioni sulle date
- Concatenare due o più campi
- Confrontare i valori di due campi
- Restituire un singolo elemento di un array invece dell'array intero

Framework di aggregazione

Un esempio: in una collezione di riviste, voglio sapere quali sono gli autori che hanno venduto più di tutti

- Project: estraggo da ogni documento l'autore della rivisita
- Group: raggruppo per autore, contando il numero di occorrenze di ciascuno
- Sort: ordino in maniera decrescente sul numero di occorrenze
- Limit: mantengo solo i primi 5 risultati

La query:

- ```
  db.articles.aggregate([
    {"$project" :  {"author" : 1}},
    {"$group" :    {"_id" : "$author", "count" : {"$sum" : 1}}},
    {"$sort" :     {"count" : -1}},
    {"$limit" :    5}
  ])
  ```
  ```

Operatore $match

L'operatore **$match** permette di **filtrare i documenti**

- Opera sostanzialmente come una query di Find
- Unica eccezione: non supporta operatori geospaziali

E' buona norma utilizzare l'operatore il prima possibile

- Riduce il numero di documenti delle operazioni successive
- Può sfruttare gli indici (in fasi successive potrebbero non essere utilizzabili)

Un esempio

- db.restaurants.aggregate([{$match: {cuisine: "Hamburger"} }])
- db.restaurants.find({cuisine: "Hamburger"})

Operatore $project

L'operatore **$project** permette di effettuare una proiezione dei campi

- E' **molto più potente** della proiezione nel comando Find
- Permette di estrarre campi da oggetti innestati e di applicare trasformazioni

db.articles.aggregate([{"$project" : {"author" : 1, "_id" : 0}}])

- Restituisce l'autore di un articolo ed esclude il campo _id

db.users.aggregate([{"$project" : {"userId" : "$_id", "_id" : 0}}])

- Rinomina il campo _id in userId
- In pratica, introduce un nuovo campo userId il cui valore corrisponde al valore di _id
- NB: l'utilizzo dell'operatore $ in "$_id" permette di indicare il riferimento ad un campo; altrimenti, "_id" verrebbe interpretato come un semplice valore

Operatore $project – espressioni matematiche

Espressioni su 1 o più valori: $add, $multiply

- "$add" : [expr1, expr2, ..., exprN]

Espressioni su 2 valori: $subtract, $divide, $mod

- "$subtract" : [expr1, expr2]
- "$divide": divide il primo valore per il secondo
- "$mod": divide il primo valore per il secondo e restituisce il resto

Un esempio

- db.employees.aggregate([{ "$project" : { "totalPay" :
  { "$subtract" : [{"$add" : ["$salary", "$bonus"]}, "$401k"] }
  } }])
- Restituisce un campo calcolato: totalPay = (salary + bonus) - 401k

Operatore $project – espressioni sulle date

Ci sono diverse espressioni che permettono di **estrarre una specifica informazione a partire da una data**

- "$year", "$month", "$week"
- "$dayOfYear", "$dayOfMonth", "$dayOfWeek"
- "$hour", "$minute", "$second"

Esempi

- db.employees.aggregate([{"$project": {"hiredIn" :{"$month" : "$hireDate"}} }])
- Restituisce il mese in cui gli impiegati sono stati assunti
- db.employees.aggregate([{"$project" : {"tenure" :
  { "$subtract" : [{"$year" : new Date()}, {"$year" : "$hireDate“}] }
  } }])
- Restituisce il numero di anni trascorsi dall’assunzione degli impiegati
- Un’operazione aritmetica tra due date restituisce un risultato in millisecondi

Operatore $project – espressioni sulle stringhe

"**$substr**" : [*expr*, *startOffset*, *numToReturn*]

- Restituisce una sottostringa della stringa passata come primo parametro; parte da *startOffset* e restituisce *numToReturn* byt
- Attenzione alla codifica: un byte potrebbe non corrispondere ad un carattere

"**$concat**" : [*expr1[, expr2, ..., exprN]*]

- Concatena le stringhe passate come parametri

"**$toLower**", "**$toUpper**"

- Restuiscono la stringa passata come parametro in tutte minuscole o maiuscolo.

Esempio

- db.employees.aggregate([{"$project" : {"email" : {"$concat" : [{"$substr" : ["$firstName", 0, 1]}, ".", "$lastName", "@example.com"] } } }])
- Restituisce una stringa come e.gallinucci@example.com

Operatore $project – espressioni logiche

Espressioni di confronto

- "**$cmp**" : [expr1, expr2]
  Confronta expr1 con expr2. Ritorna 0 se sono uguali, un numero negativo se expr1 < expr2, un numero positivo se expr1 > expr2.
- "**$strcasecmp**" : [string1, string2]
  Confronto case-insensitive tra due stringhe
- "**$eq**"/"**$ne**"/"**$gt**"/"**$gte**"/"**$lt**"/"**$lte**" : [expr1, expr2]
  Confronta expr1 con expr2 e ritorna true o false

Espressioni booleane

- "**$and**", "**$or**" : [*expr1[, expr2, ..., exprN]*]
  Ritorna vero se tutte ($and) o almeno una ($or) delle espressioni è vera
- "**$not**" : *expr*
  Ritorna il valore booleano opposto di *expr*

Operatore $project – espressioni logiche

Espressioni di controllo

- "**$cond**" : [*booleanExpr*, *trueExpr*, *falseExpr*]
  Se l'espressione *booleanExpr* è vera, ritorna *trueExpr*, altrimenti *falseExpr*
- "**$ifNull**" : [*expr*, *replacementExpr*]
  Se *expr* vale null, ritorna *replacementExpr*, altrimenti ritorna *expr*

Un esempio: gli studenti vengono valutati per il 10% sulla presenza, 30% sulle interrogazioni, 60% sulle verifiche; ma prendono 100 se sono "cocchi"

```
db.students.aggregate([{"$project" : {"grade" : {"$cond" :
  ["$teachersPet", 100,
    {"$add" : [
      {"$multiply" : [.1, "$attendanceAvg"]},
      {"$multiply" : [.3, "$quizzAvg"]},
      {"$multiply" : [.6, "$testAvg"]}
    ]}
  ]}
} }])
```

Operatore $group

L'operatore **$group** permette di raggruppare i documenti sulla base di determinate chiavi e di calcolare dei valori aggregati. Alcuni esempi:

- Contesto: misurazioni meteo minuto-per-minuto.
  Query: umidità media per giorno
- Contesto: collezione di studenti
  Query: raggruppare gli studenti per voto
- Contesto: collezione di utenti
  Query: raggruppare gli utenti per città e stato

I campi su cui si vuole raggruppare costituiscono le chiavi del gruppo

- {"$group" : {"_id" : "$day"}}
- {"$group" : {"_id" : "$grade"}}
- {"$group" : {"_id" : {"state" : "$state", "city" : "$city"}}}

Operatore $group ed operatori aritmetici

Oltre a specificare le chiavi su cui raggruppare è possibile indicare una o più operazioni per calcolare valori aggregati.

Gli operatori aritmetici sono due:

- "**$sum**" : value
  Produce la somma dei valori
- "**$avg**" : value
  Produce la media dei valori

Un esempio completo

- ```
  db.sales.aggregate([{"$group" : {
    "_id" : "$country",
    "totalRevenue" : {"$avg" : "$revenue"},
    "numSales" : {"$sum" : 1}
  } }])
  ```
  ```

Operatore $group ed operatori su estremi

Ci sono quattro operatori per ottenere gli "**estremi**" del dataset:

- "**$max**" : *expr ;* **"$min**" : *expr*
  Esaminano tutti i documenti e restituiscono rispettivamente il massimo ed il minimo valore trovato
- "**$first**" : *expr ;* "**$last**" : *expr*
  Esaminano solo il primo e l'ultimo documento per restituire il valore trovato

Due esempi

- db.scores.aggregate([{"$group" : {
  "_id" : "$grade",
  "lowestScore" : {"$min" : "$score"},
  "highestScore" : {"$max" : "$score"}
  } }])

```
db.scores.aggregate([
  {"$sort" : {"score" : 1} },
  {"$group" : {
    "_id" : "$grade",
    "lowestScore" : {"$first" : "$score"},
    "highestScore" : {"$last" : "$score"}
  }
}])
```

Operatore $group ed operatori di collezione

Ci sono due operatori che consentono di costruire un array con i valori riscontrati in ciascun gruppo

- "**$addToSet**" : *expr*
  Costruisce un array con tutti i valori distinti
- "**$push**": *expr*
  Costruisce un array con tutti i valori trovati, anche duplicati

Un esempio

- db.sales.aggregate([{"$group" : {
  "_id" : { day : { $dayOfYear: "$date"}, year: { $year: "$date" } },
  "itemsSold" : { $addToSet: "$item" }
  } }])
  Restituisce l'elenco distinto dei prodotti venduti in ciascun giorno

Operatore $unwind

L'operatore **$unwind** permette di *appiattire* un array, costruendo tanti documenti quanti sono gli elementi dell'array

- {
  _id: 1,
  categories: ['A','B','C']
  }

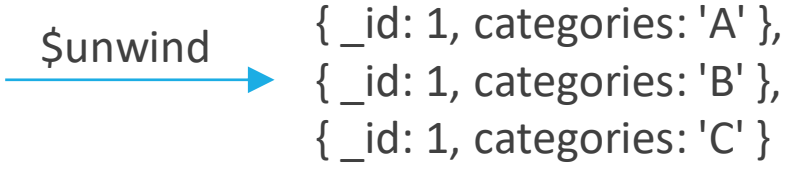

Ciò torna utile per effettuare proiezioni e aggregazioni sugli elementi interni degli array

- db.blog.aggregate([
  {"$project" : {"comments" : "$comments"} },
  {"$unwind" : "$comments"},
  {"$match" : {"comments.author" : "Mark"} }
  ])
  Restituisce i commenti di Mark

Operatore $unwind

Un altro esempio

- { _id: 1, nome: "Enrico", città: "Cesena", voti: [1, 2, 3],
  { _id: 2, nome: "Lorenzo", città: "Cesena", voti: [4, 5, 6] },
  { _id: 3, nome: "Matteo", città: "Trieste", voti: [7, 8, 9] }
- db.col.aggregate([
  {"$unwind" : "$voti"},
  {"$group" : {"_id" : "$città", "mediaVoti": { "$avg" : "$voti" } } },
  ])
  Restituisce la media dei voti per città

Se l'array contiene un altro array, è possibile applicare l'operatore $unwind in cascata (prima sull'array esterno, poi su quello interno)

Operatore $unwind

L'operatore $unwind può essere dichiarato anche come un oggetto, in cui indicare (oltre al campo da appiattire) alcuni parametri opzionali

- $unwind: {
  path: <field path>,
  includeArrayIndex: <string>,
  preserveNullAndEmptyArrays: <boolean>
  }
- **path** è il percorso dell'array (come nella versione semplice)
- **includeArrayIndex** è il nome di un nuovo campo in cui si vuole estrarre l'indice posizionale dell'array
- **preserveNullAndEmptyArrays**, se impostato a true, permette di restituire un documento anche se l'array indicato non esiste (oppure è null o vuoto)

Operatore $unwind

Un esempio con la versione estesa di $unwind

- { _id: 1, nome: "Enrico", città: "Cesena", voti: [1, 2, 3],
  { _id: 1, nome: "Lorenzo", città: "Cesena", voti: [4, 5, 4] }

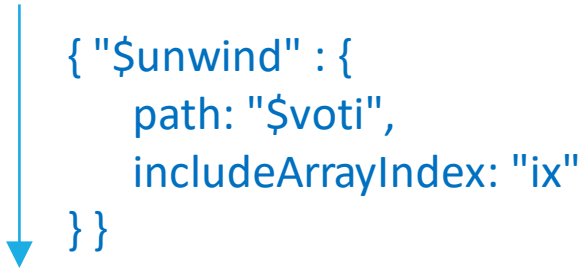

- { _id: 1, nome: "Enrico", città: "Cesena", voti: 1, ix: 0 },
  { _id: 1, nome: "Enrico", città: "Cesena", voti: 2, ix: 1 },
  { _id: 1, nome: "Enrico", città: "Cesena", voti: 3, ix: 2 },
  { _id: 2, nome: "Lorenzo", città: "Cesena", voti: 4, ix: 0 },
  { _id: 2, nome: "Lorenzo", città: "Cesena", voti: 5, ix: 1 },
  { _id: 2, nome: "Lorenzo", città: "Cesena", voti: 6, ix: 2 }

Operatori $sort, $limit e $skip

Gli operatori **$sort**, **$limit** e **$skip** funzionano come nella formulazione delle interrogazioni semplici

- Se si vuole ordinare un grande numero di documenti, è buona norma fare l'ordinamento il prima possibile lungo la pipeline e avere un indice sul campo

Un esempio

- ```
  db.employees.aggregate([
    { "$project" : {
      "compensation" : { "$add" : ["$salary", "$bonus"] },
      "name" : 1
    } },
    { "$sort" : {"compensation" : -1, "name" : 1} }
  ])
  ```
- E' possibile ordinare anche sui campi creati lungo la pipeline
  ```

Lookup

Operatore $lookup

Introdotto a partire dalla versione 3.2

L'operatore **$lookup** permette di eseguire il left outer join tra collezioni residenti nello stesso database

- Nella collezione «primaria» viene creato un nuovo campo di tipo *array*, contenente gli eventuali documenti corrispondenti nella collezione «secondaria»

La sintassi:

- $lookup: {
  from: <collection to join>,
  localField: <field from the input documents>,
  foreignField: <field from the documents of the "from" collection>,
  as: <output array field>
  }

Operatore $lookup

Collezione **orders**

- { "_id" : 1, "item" : "abc", "price" : 12, "quantity" : 2 }
- { "_id" : 2, "item" : "jkl", "price" : 20, "quantity" : 1 }
- { "_id" : 3 }

Collezione **inventory**

- { "_id" : 1, "sku" : "abc", description: "product 1", "instock" : 120 }
- { "_id" : 2, "sku" : "def", description: "product 2", "instock" : 80 }
- { "_id" : 3, "sku" : "ghi", description: "product 3", "instock" : 60 }
- { "_id" : 4, "sku" : "jkl", description: "product 4", "instock" : 70 }
- { "_id" : 5, "sku": null, description: "Incomplete" }
- { "_id" : 6 }

Operatore $lookup

Esempio di lookup

```
db.orders.aggregate([{
  $lookup: {
    from: "inventory",
    localField: "item",
    foreignField: "sku",
    as: "inventory_docs"
  }
}])
```

Risultato →

```
{
 "_id" : 1,
 "item" : "abc",
 "price" : 12,
 "quantity" : 2,
 "inventory_docs" : [
  { "_id" : 1, "sku" : "abc",
    description: "product 1", "instock" : 120 }
 ]
}
..
{
 "_id" : 3,
 "inventory_docs" : [
  { "_id" : 5, "sku" : null, "description" : "Incomplete" },
  { "_id" : 6 }
 ]
}
```

Nuove collection

Statistiche NBA

- http://www.mediafire.com/file/ju52cn1eadiydz6/NBA2016.json
- 1 documento contenente statistiche relative alla stagione 2016/17 per tutti i giocatori e tutte le squadre
- Modificato per separare le statistiche su giocatori e squadre in due file

Statistiche città USA

- https://gist.githubusercontent.com/Miserlou/c5cd8364bf9b2420bb29/raw/2bf258763cdddd704f8ffd3ea9a3e81d25e2c6f6/cities.json
- 1000 documenti con statistiche sulle città più popolose negli Stati Uniti d'America

```
mongoimport --collection nba2016players --db test
C:\nba2016players.json --jsonArray
```